



Universidad de Buenos Aires — Taller de Programación (2026)

Trabajo Práctico 1

Un primer encuentro con la EPH

Informalidad laboral entre trabajadores independientes (informal self-employed)

Grupo 8

Docente: Noelia Romero

Integrantes: Mayra Lemes Lapasta y Javier Hernández Aldana

Repositorio del grupo:

https://github.com/mayleemes/TPs_Programacion_Grupo8

Parte I. Familiarización con la EPH y limpieza de datos

En la EPH, el INDEC identifica la informalidad de los asalariados por la registración del puesto, es informal quien trabaja sin descuento jubilatorio (variable PP07H). Desde las bases de 2024 el instituto incorpora además dos clasificaciones ya construidas, EMPLEO, que marca si el puesto es formal o informal, y SECTOR, que clasifica la unidad económica (sector formal, informal o de hogares) según sus características productivas y de registro. Los trabajadores independientes no tienen un empleador que los registre, así que su clasificación se apoya en atributos del emprendimiento; la Parte III construye una medida alternativa para ese grupo siguiendo a Maurizio & Monsalvo (2021) y la contrasta con la variable EMPLEO.

Se trabajó con las bases individuales de los cuartos trimestres de 2024 y 2025 (46.860 y 43.703 observaciones), descargadas del sitio del INDEC junto con sus diseños de registro. A las 13 variables obligatorias se sumaron 7 de interés: aportes jubilatorios del independiente (PP05I), emisión de factura (PP05K), ámbito estatal o privado (PP04A), horas trabajadas (PP3E_TOT), intensidad laboral (INTENSI), aglomerado y el ponderador de ingreso de la ocupación principal (PONDIIIO). ¹Las primeras cuatro se eligieron por su relación directa con la informalidad de los independientes, el universo asignado al grupo. El chequeo de consistencia de nombres y tipos entre años no detectó diferencias.

Los ingresos traen el código -9 de no respuesta (ningún ingreso puede ser negativo): 8.189 casos en P21 y 11.458 en P47T. El cero se conservó, porque identifica a quien legítimamente no percibe ingreso por esa fuente. El segundo tipo son los códigos 9, 99 y 999 de Ns/Nr en las categóricas y en horas trabajadas, que aparecen como números válidos pero no lo son: dejar el 99 del tamaño del establecimiento equivaldría a atribuirle 99 empleados. Ambos se convirtieron a valores faltantes sobre la base completa, antes de cualquier partición, para que el análisis de faltantes mida no respuesta real y no la codificación.

La partición por condición de actividad identificó 121 entrevistas individuales no realizadas (base no respondieron, 0,1% del total); las 90.442 restantes conforman la base respondieron, de las cuales 40.830 están ocupadas (21.132 en 2024 y 19.698 en 2025). Las variables dicotómicas se crearon con criterio de parsimonia, en la cobertura médica se aisló la carencia total (rasgo estructural de la informalidad) y en la intensidad, la subocupación horaria; las ordinales con orden natural se conservaron sin transformar. Los ingresos de 2024 se llevaron a pesos del cuarto trimestre de 2025 con un coeficiente de 1,3141, el cociente de los promedios del IPC nacional de octubre a diciembre de cada año (INDEC, 2026), consistente con el período de relevamiento y menos volátil que un mes puntual.

Figura 1. Los faltantes se concentran en ocupación e ingresos.
(porcentaje)




Figura 1. Porcentaje de valores faltantes por grupo de variables, según base y año.

El heatmap distingue tres situaciones. Las variables sociodemográficas están completas en ambas bases. Las de ocupación faltan en 55-61% de respondieron porque el cuestionario no las aplica a quienes no trabajan; entre ocupados esa falta casi desaparece, aunque persiste no respuesta genuina en el tamaño del establecimiento (13-14%) y el sector

¹ PONDIIIO es el ponderador del ingreso de la ocupación principal, corregido por no respuesta de ingresos; se incluye por su relevancia para el análisis del ingreso, aunque no constituye una variable de análisis en sí misma. Para las proporciones de informalidad (Parte III) se utiliza el ponderador general PONDERA.

(4%). Los ingresos son el caso más serio, la no respuesta alcanza 20% en P21 y 22% en P47T entre ocupados y se concentra precisamente en quienes perciben ingreso laboral.

Parte II. Primer análisis exploratorio




Figura 2. Matrices de correlación, 2024T4 y 2025T4. Categóricas como dummies; nivel educativo ordinal recodificado; ingresos en pesos de 2025T4.

Las categóricas ingresaron a la matriz mediante sus *dummies* y el nivel educativo como ordinal recodificado (el código 7, "sin instrucción", pasó a 0 para no invertir la escala). ESTADO, pedida por la consigna, no aparece por que la base ocupados retiene solo ESTADO = 1, la variable es constante y su correlación no está definida. Las estructuras de los dos años son casi idénticas, ninguna de las diferencias supera 0,04 en valor absoluto (Apéndice A. Fig. 3), lo que descarta que la comparación entre trimestres esté distorsionada por cambios de composición. Tres relaciones concentran la lectura económica: P21 y P47T correlacionan 0,92-0,94, así que para los ocupados el ingreso total es esencialmente el laboral; la falta de cobertura médica se asocia negativamente con educación e ingresos (-0,29 a -0,34), el rastro clásico de la informalidad; y el sector informal de la unidad económica se asocia con el cuentapropismo (0,57-0,59) y con la falta de cobertura (0,51-0,52), un anticipo de lo que la Parte III mide con definición propia.

La estadística descriptiva (Apéndice B. Tabla 2) deja dos lecturas. La primera es distributiva, el ingreso real de la ocupación principal creció entre trimestres, pero no de manera pareja. El p25 y la mediana subieron 21,8% (de \$328.527 a \$400.000 y de \$657.053 a \$800.000, en pesos de 2025T4), la media 10,8% y el p99 apenas 1,5%, una mejora concentrada en la base y el medio de la distribución, con la cola alta casi estancada. La segunda es de calidad del dato, los percentiles de 2025 caen en cifras redondas (\$400.000, \$800.000, \$1.200.000), se retoma más adelante al discutir las limitaciones.

Parte III. Informalidad laboral: informal self-employed

Siguiendo a Maurizio & Monsalvo (2021), el universo son los patrones, cuentapropistas y familiares sin remuneración (CAT_OCUP 1, 2 y 4) del sector no estatal, son 11.595 casos (5.840 en 2024 y 5.755 en 2025). Un patrón es formal si su establecimiento supera las cinco personas (PP04C ≥ 6, el corte coincide con el agrupamiento en tramos del INDEC) y un cuentapropista solo si es profesional, que se corresponde con superior universitaria completa (NIVEL_ED = 6, condición de igualdad estricta porque el código 7, "sin instrucción", no pertenece a la escala 1-6). Los familiares sin remuneración son informales en todos los casos. La formalidad exige información acerca del tamaño o título, por lo que los 53 patrones con tamaño sin declarar (30 y 23 por año, menos del 1% del universo) quedaron sin clasificar en lugar de imputarse.


Tabla 1. Trabajadores independientes formales e informales por sexo y año (porcentajes ponderados por PONDERA).

	2024T4			2025T4		
	Total	Mujeres	Varones	Total	Mujeres	Varones
Formal	21,4	26,0	18,4	19,8	24,3	16,8
Informal	78,6	74,0	81,6	80,2	75,7	83,2

Cuatro de cada cinco independientes son informales: 78,6% en 2024T4 y 80,2% en 2025T4, un aumento de 1,6 puntos entre trimestres y una proporción consistente con la que Maurizio & Monsalvo reportan para Argentina. Las mujeres presentan menor informalidad que los varones en ambos años (74,0% contra 81,6% en 2024; 75,7% contra 83,2% en 2025). El patrón puede resultar contraintuitivo, pero es composicional, la proporción de cuentapropistas con universitaria completa es 24,3% entre las mujeres y 14,0% entre los varones, así que la brecha refleja la composición educativa del cuentapropismo femenino y no una ventaja general de las mujeres en el mercado independiente. Como validación externa, la clasificación coincide en 71,3% (proporción simple, sin ponderar) con la variable EMPLEO del INDEC, y el desacuerdo tiene dirección, se concentra en 2.737 casos que el criterio productivo marca como informales pero que el INDEC registra como formales, porque el instituto clasifica por registración efectiva y el paper por proxies de capacidad productiva.

Figura 3. Distribución del ingreso de los independientes formales e informales. Ingresos positivos en pesos de 2025T4, recortados entre p1 y p99; densidades normalizadas por grupo.

Figura 4. Distribución del ingreso de trabajadores formales e informales



Los cuatro paneles cuentan la misma historia, la distribución de los informales se concentra en un pico agudo de ingresos bajos, con la moda cerca de los \$400.000, mientras que la de los formales es más achatada, está desplazada a la derecha y conserva una cola larga. La mediana de P21 de los formales duplica exactamente a la de los informales (\$919.874 contra \$459.937); en el ingreso total la brecha se comprime a 1,8 veces (\$1.051.285 contra \$572.468), porque las fuentes no laborales amortiguan la diferencia. Al mismo tiempo, ambas colas se superponen, hay informales de ingresos altos y formales de ingresos modestos, la heterogeneidad interna que motiva el enfoque por niveles del paper. La elección de 50 barras y del ancho de banda por defecto se validó explorando la sensibilidad del estimador a ambos parámetros (Apendice B. Fig. 5), con pocos bins el histograma esconde la forma y con demasiados domina el ruido de los montos redondos; el kernel sobreajusta con ancho de banda bajo y borra la asimetría real con uno alto.

Retomando, las dos variables de ingreso tienen limitaciones, la no respuesta alcanza 20-22% de los ocupados y difícilmente sea aleatoria, los ingresos altos y los muy informales tienden a no declarar. Los montos declarados en encuestas de hogares suelen subdeclararse, en particular entre independientes, y la concentración en cifras redondas apunta en esa dirección. P47T mezcla el fenómeno de interés (el retorno del trabajo independiente) con transferencias y rentas, por lo que compara peor que P21 entre estatus laborales. Y los familiares sin remuneración quedan fuera del gráfico por construcción, al no percibir ingreso.

Parte IV. Reflexión sobre el uso de inteligencia artificial

El desarrollo de este trabajo se apoyó en herramientas de inteligencia artificial (IA) como asistencia para la programación en Python y para la discusión de decisiones metodológicas. Se le dio uso para explicar funciones, ayuda para solo aplicar lo visto en clase paso a paso pero con una base de datos más compleja.

Algunas sugerencias que dio la IA no eran muy precisas, en algunos casos se detectó y corrigió errores o imprecisiones en las respuestas, por ejemplo, con la carga y consistencia de bases, la IA sugirió PP07H/PP07I y lo corregimos cuando verificamos que estaban vacías. También en el análisis exploratorio y correlaciones hubo una confusión con SECTOR vs sector_privado, en el tratamiento de categóricas.

En cuanto a la distribución del trabajo, ambos integrantes participamos en el desarrollo del código y del análisis, lo que queda reflejado en el historial de contribuciones del repositorio de GitHub.

Tiempo total aproximado dedicado al trabajo práctico: Mayra Lemes dedicó unas 20 h repartidas en la semana, concentradas unas 10 h el fin de semana; Javier Hernández dedicó unas 24 durante toda la semana aproximadamente.

Referencias

- INDEC (2026). Índice de precios al consumidor, nivel general. Serie mensual, base diciembre 2016 = 100.
- Maurizio, R. y Monsalvo, A. P. (2021). Informality, labour transitions, and the livelihoods of workers in Latin America. WIDER Working Paper 2021/19, UNU-WIDER.
- Schwabish, J. A. (2014). An economist's guide to visualizing data. Journal of Economic Perspectives, 28(1), 209-234.

Apéndice A.


Análisis exploratorio

Las estructuras de los dos años son casi idénticas, ninguna de las diferencias supera 0,04 en valor absoluto:

Figura 3

Cambio en las correlaciones entre 2024T4 y 2025T4

Diferencia (2025 – 2024): valores cercanos a 0 (blanco) indican correlaciones estables




Apéndice B. Estadística descriptiva de las variables numéricas

Base: ocupados. N corresponde a las observaciones válidas de cada variable. Ingresos en pesos del cuarto trimestre de 2025. El tamaño del establecimiento (PP04C) se releva en tramos: los códigos 1 a 5 son cantidades exactas de personas y del 6 en adelante son rangos (6 = 6-10, hasta 12 = más de 500), por lo que sus estadísticos se leen como códigos. La tabla completa de las 20 variables seleccionadas, incluidas las frecuencias de las categóricas, se reporta en el notebook del repositorio.

Tabla 2: descriptiva de las variables NUMÉRICAS, por año:

Año	Variable	N	Promedio	Desvío	Mín	p1	p25	p50	p75	p99	Máx
2024T4	Edad (años)	21.132	41	13	11	19	31	40	51	73	92
	Ingreso ocup. principal (\$)	16.857	827.594	806.803	0	0	328.527	657.053	1.051.285	3.942.319	19.711.593
	Ingreso total (\$)	16.466	939.745	877.854	0	0	420.514	775.323	1.182.696	4.073.729	21.682.752
	Tamaño establec. (tramo)	18.423	5	4	0	0	1	5	8	12	12
	Horas trab. semanales	21.088	36	16	0	0	25	40	48	84	154
2025T4	Edad (años)	19.698	42	13	12	19	31	41	52	73	100
	Ingreso ocup. principal (\$)	15.784	917.209	909.163	0	0	400.000	800.000	1.200.000	4.000.000	30.000.000
	Ingreso total (\$)	15.384	1.040.595	1.010.776	0	0	500.000	800.000	1.300.000	4.500.000	30.000.000
	Tamaño establec. (tramo)	17.004	5	4	0	0	1	4	8	12	12
	Horas trab. semanales	19.655	36	16	0	0	25	40	48	84	168

Fig.5. Explorando la sensibilidad del estimador a ambos parámetros.



Apéndice C. Registro de prompts a la inteligencia artificial

Se documentan a continuación los prompts más representativos utilizados durante el desarrollo del trabajo, organizados por etapa. El criterio de uso fue consultivo: la herramienta asistió en la escritura y depuración del código en Python y en la discusión metodológica, mientras que cada resultado se verificó contra las fuentes primarias (diseño de registro del INDEC y Maurizio & Monsalvo, 2021) antes de incorporarlo. Se incluyen deliberadamente los casos en que la herramienta cometió errores y el grupo los detectó y corrigió, por considerarlos parte central del aprendizaje.

1. Carga y consistencia de las bases

Prompt 1.1: Selección de variables de interés (revisión crítica)

Para el grupo informal self-employed, ¿qué variables de la EPH conviene sumar a las obligatorias paramedir informalidad de independientes? Estaba pensando en PP07H y PP07I.

Resultado y verificación: La herramienta sugirió PP07H/PP07I, pero al verificar empíricamente en la base resultaron vacías para los independientes (son de asalariados: descuento jubilatorio del empleador). Se descartaron y se seleccionaron en su lugar PP05I (aportes del independiente) y PP05K (emisión de factura), que sí aplican al universo del grupo.

2. Limpieza de datos

Prompt 2.1 :Códigos de no respuesta

En la EPH los ingresos traen -9 como código de no respuesta y las categóricas traen 9, 99 o 999. Cómo los convierto a valores faltantes sin borrar los ceros legítimos de ingreso?

Resultado y verificación: Se reemplazaron los códigos por NaN sobre la base completa, antes de particionar, conservando los ceros de ingreso (que identifican a quien legítimamente no percibe ingreso por esa fuente).

Prompt 2.2 :Orden de limpieza

"Nuestro heatmap de faltantes da 0% en las variables de ocupación, pero más adelante PP04C tiene miles de NaN. Sospechamos que es por el orden en que hicimos la limpieza, ¿lo puedes confirmar?"

Resultado y verificación: se confirmó la hipótesis del grupo: la conversión de los códigos 9/99/999 estaba después del análisis de faltantes, que por eso medía la codificación y no la no respuesta. Se movió la limpieza al inciso 2.b y el heatmap pasó a reflejar la no respuesta genuina (12,8-13,7% en tamaño del establecimiento)

3. Análisis exploratorio y correlaciones

Prompt 3.1:Variable SECTOR (revisión de una confusión)

La consigna pide la variable SECTOR en la matriz. Yo había usado sector_privado (de PP04A). Quisiera verificar si son lo mismo.

Resultado y verificación: No son lo mismo: SECTOR clasifica la unidad económica (formal/informal/hogares) y PP04A el ámbito (estatal/privado). Se corrigió la matriz para usar una dummy construida a partir de SECTOR, como pide la consigna.

Prompt 3.2. Tratamiento según tipo de variable en la descriptiva

La tabla descriptiva con media y percentiles no tiene sentido para variables categóricas como sexo o sector. Cómo trato cada tipo de variable.

Resultado y verificación: Se separó el tratamiento: estadística descriptiva (media, desvío, percentiles) para las variables numéricas, y tablas de frecuencia (conteo y proporción) para las categóricas, siguiendo el criterio de la cátedra.

Prompt 3.3. Elección del deflactor

"Para llevar los ingresos de 2024T4 a pesos de 2025T4, ¿es más apropiado el IPC de un mes puntual o el promedio del trimestre?"

Resultado y verificación: se adoptó el promedio de octubre-diciembre de cada año (coeficiente 1,3141), consistente con el período de relevamiento de la EPH y menos sensible a la volatilidad mensual.

4. Construcción del indicador de informalidad

Prompt 4.1. Lógica de clasificación (corrección de una sobre-atribución)

Según Maurizio & Monsalvo, confírmame si construyo el indicador de informalidad para los self-employed con una definición que aplica el filtro de tamaño ≤ 5 empleados a todo el universo.

Resultado y verificación: Al contrastar con el Box 1 del paper, se detectó que el filtro de tamaño aplica solo a los patrones, no a todo el universo. La lógica correcta asigna a cada categoría su criterio: patrón informal si ≤ 5 empleados; cuentapropista informal si no es profesional; familiar sin remuneración siempre informal. Se corrigió en consecuencia.

Prompt 4.2. Validación externa del indicador

"Queremos contrastar nuestro indicador contra la variable EMPLEO del INDEC como chequeo de razonabilidad. ¿Cómo interpretamos las divergencias?"

Resultado y verificación: la coincidencia simple fue 71,3%, con el desacuerdo concentrado en 2.737 casos que el criterio productivo marca informales pero el INDEC registra como formales — la dirección esperable, dado que el instituto clasifica por registración efectiva y el paper por proxies productivos.