



Universidad de Buenos Aires - Taller de Programación (2026)

Trabajo Práctico 2

Métodos No Supervisados usando la EPH

Informalidad laboral entre trabajadores independientes (informal self-employed)

Grupo 8

Docente: Noelia Romero

Integrantes: Mayra Lemes Lapasta y Javier Hernández Aldana

Repositorio del grupo:

https://github.com/maylemes/TPs_Programacion_Grupo8

Parte I. Creación de variables y estadística descriptiva

Trabajamos con el universo *self-employed* definido en el TP1 (11.595 casos del T4 de 2024 y 2025, incluyendo patrones, cuentapropistas y familiares no remunerados). Filtramos este grupo ya que el indicador de informalidad de Maurizio & Monsalvo (2021) no aplica a asalariados. Desde las bases del INDEC, el notebook reproduce la limpieza, deflactación a pesos de 2025 y cálculo del indicador, reconfirmando la tasa de informalidad del 81,3%.

1. Creación de variables

Creamos cuatro variables. La primera (*edad²*), que captura la forma no lineal que tiene el ingreso a lo largo de la vida laboral. La segunda (*educ*), refiere a los años de educación y la armamos combinando el nivel más alto cursado (*CH12*), si se finalizó (*CH13*) y el último año aprobado (*CH14*) donde cada nivel suma los años de los niveles anteriores más su propia duración si se completó, o solo los años aprobados si quedó a mitad de camino.¹ El mapeo se construyó a partir del ejemplo de la consigna donde secundario terminado equivale a 12 años. Para validarlo cruzamos (*educ*) contra (*CH12*), los 3.461 casos de secundario completo reciben todos 12 años (Apéndice B). Quedan 133 observaciones sin dato por no respuesta en alguna de las tres variables.

La tercera variable (*horastrab*) hace referencia a las horas totales trabajadas, suma las horas de la ocupación principal y las de otras ocupaciones (*PP3E_TOT* + *PP3F_TOT*), con los códigos “999” de no respuesta pasados a faltante. La consigna la pide para el jefe de hogar, pero como la usamos después en el PCA y el Clúster para toda la base, la calculamos para todos los ocupados. Y, por último, la cuarta hace referencia a la cantidad de miembros del hogar (*nhogar*). La contamos sobre la base completa, que incluye a menores e inactivos y no solo a los independientes, agrupando por vivienda (*CODUSU*), hogar (*NRO_HOGAR*) y año. Para chequear que estuviera bien, la comparamos contra (*IX_TOT*), el total de miembros que el INDEC ya trae calculado en la base de hogares. Coinciden en el 100% de los casos.

2. Estadística descriptiva

La composición del universo cambia poco entre un trimestre y otro. La mediana de edad pasa de 44 a 45 años, y tanto las horas totales (40h) como el tamaño mediano del hogar (3 personas) se mantienen. La educación mediana también queda en 12 años, es decir secundario completo, lo que sugiere que estamos ante un perfil de trabajadores independientes bastante parecido en ambos períodos. Donde sí hay movimiento es en los ingresos. El ingreso mediano nominal de la ocupación principal sube de \$320.000 a \$500.000, un incremento del 56,2%, pero medido en pesos constantes de 2025T4, la mejora real es del 18,9%, en línea con la recuperación que ya habíamos visto en el TP1. En todas las variables de ingreso la media queda muy por encima de la mediana, la asimetría habitual de estas distribuciones, y los máximos de \$30 millones son un puñado de casos extremos que después vuelven a aparecer en el PCA. La tabla completa está en el Apéndice C.

Inciso 3. Matriz de correlaciones


Como se observa, a continuación, en la (figura 1) estamos ante correlaciones bajas a medianas, y muy parejas entre años. La informalidad se asocia sobre todo con los años de educación (-0,61 en 2024 y -0,60 en 2025). Bastante más atrás quedan el ingreso de la ocupación principal (-0,27 y -0,26) y el tamaño del establecimiento (-0,19 y -0,22). El resto de los predictores no llega a 0,15 en valor absoluto, la edad y *edad²* casi no se mueven con la informalidad, y el tamaño del hogar casi no se asocia de forma positiva (0,15 y 0,14). Sobre la segunda pregunta de la consigna, los coeficientes no cambian de un año a otro, la diferencia más grande es de 0,03, en el tamaño del establecimiento. La estructura de correlaciones es idéntica en ambos trimestres.

Sin embargo, no hay que olvidar que la correlación con la educación está inflada por la propia definición del indicador, como clasificamos al cuentapropista con universitario completo como formal, educación e informalidad quedan atadas por construcción. Al separar por categoría, la correlación es de -0,67 entre cuentapropistas (el 85% de la muestra) pero de apenas -0,21 entre patrones, que se clasifican por el tamaño del establecimiento y no por el título. Y también edad y *edad²* correlacionan 0,99. Al entrar las dos entre los

¹ CH12 releva niveles de dos sistemas educativos que conviven en la EPH: primaria/secundaria por un lado y EGB/polimodal por otro. Adoptamos las duraciones convencionales de cada trayectoria (7+5 y 9+3 respectivamente), de modo que ambas convergen en 12 años de escolaridad y secundario y polimodal completos reciben el mismo valor. Para los niveles superiores suponemos terciario de 3 años, universitario de 6 y posgrado de 4. Estas duraciones son supuestos: la estructura de niveles varía entre provincias y la EPH no permite distinguirla. Quienes nunca asistieron y los casos de educación especial se codifican con 0.

siete predictores, la dimensión etaria pesa el doble en el cálculo de distancias y en la descomposición de varianza, lo que anticipa por qué termina dominando los métodos de la Parte II.

Figura 1. Correlaciones entre informalidad y predictores, universo self-employed



Fuente: elaboración propia en base a EPH-INDEC, 4° trimestre 2024 y 2025.


Figura 1. Correlaciones entre informalidad y predictores, universo self-employed, por año.

Parte II. Métodos no supervisados

A. Análisis de componentes principales (PCA)

Antes de aplicar PCA estandarizamos las siete variables a media 0 y desvío 1. Sin este paso, el ingreso, medido en pesos, dominaría los componentes por su escala frente a variables como los miembros del hogar o los años de educación. Trabajamos con los 8.520 casos que tienen información completa y clasificación definida. La diferencia con los 11.595 se explica sobre todo por la no respuesta en ingresos. La submuestra mantiene la composición del universo (82,5% de informales frente al 81,3% del total), así que no parece haber un problema de selección importante. Si bien la consigna pide usar P21 nominal, al juntar dos trimestres con inflación de por medio repetimos el PCA con el ingreso real como chequeo. Las proporciones de varianza explicada coinciden al primer decimal.

Figura 3. Scores y ponderadores de los dos primeros componentes



Fuente: elaboración propia en base a EPH-INDEC, 4° trimestre 2024 y 2025.

Figura 2. Scores (panel A, rojo = informal) y ponderadores (panel B) del primer y segundo componente.


En el panel A no aparece ningún patrón que distinga formales de informales, ambos grupos se mezclan en casi todo el plano. Como mucho, se nota una densidad algo mayor de formales hacia la zona de PC2 positivo, justo donde apuntan las flechas de ingreso, educación y tamaño del establecimiento. Los outliers sí

se distinguen bien: unas pocas observaciones se van hacia arriba y a la derecha, y son los ingresos extremos de hasta \$30 millones que ya habíamos visto en la descriptiva (Apéndice D). El panel B muestra cómo se arman los componentes. PC1 queda capturado casi por completo por el par edad-edad² (cargas de 0,67 cada una), que concentra la redundancia entre las dos. PC2, en cambio, junta las variables económicas como el ingreso (0,58), educación (0,48) y tamaño del establecimiento (0,47), con el tamaño del hogar tirando en sentido contrario. En resumen, el primer eje ordena por edad y el segundo por nivel socioeconómico.

Tabla 1. Ponderadores (loadings) de las variables sobre los dos primeros componentes.

VARIABLE	PC1	PC2
EDAD	0,671	-0,090
EDAD ²	0,671	-0,106
AÑOS DE EDUCACIÓN	-0,054	0,484
HORAS TOTALES TRAB.	0,017	0,385
MIEMBROS DEL HOGAR	-0,281	-0,190
INGRESO OCUP. PPAL.	0,119	0,584
TAMAÑO DEL ESTABLEC.	0,059	0,471

Figura 4. Proporción de la varianza explicada



Fuente: elaboración propia en base a EPH-INDEC, 4° trimestre 2024 y 2025.


Figura 3. Proporción de la varianza explicada, individual y acumulada.

La varianza se reparte de a poco entre los componentes 30,1%, 22,4%, 15,5%, 12,3%, 10,5% y 9,0%. Hacen falta cinco para pasar el 90%, y no hay un codo claro. Volviendo al inciso I.3, este es justo el caso que la simulación de clase asocia a correlaciones bajas, si los predictores no comparten información, PCA no puede resumirla en pocas dimensiones. En un contexto de correlaciones altas pasaría lo contrario, con el primer componente llevándose casi toda la varianza. La única señal de redundancia es el par edad-edad², con su correlación de 0,99, que deja al séptimo componente explicando apenas 0,2%.

B. Análisis de clúster
K-medias

Corrimos k-medias con k=2 sobre las siete variables estandarizadas, con iniciación aleatoria y 20 arranques para no quedar atrapados en un mínimo local. El algoritmo no logra separar formales de informales, un clúster tiene 83,0% de informales y el otro 81,7%, valores que no se distinguen del 82,5% general. Lo que sí separa es la edad, con promedios de 35,2 y 58,7 años, mientras que el resto de las variables queda parecido entre grupos. Tiene sentido a la luz del PCA, como la edad entra dos veces (por edad y edad²), pesa el doble en las distancias y termina mandando en la partición.

El método del codo, con k de 1 a 40 (Figura 4), refuerza lo mismo. La inercia baja de forma suave, sin ningún salto marcado, las caídas son del 20,7%, 13,9% y 10,3% al principio y después se aplanan. Si igual tuviéramos que elegir un número, los mejores serían 3 o 4, donde se concentran las últimas bajas. Pero estos datos, con correlaciones tan bajas, no tienen grupos naturales bien definidos.




Fuente: elaboración propia en base a EPH-INDEC, 4° trimestre 2024 y 2025.

Figura 4. Método del codo (Elbow) para k-medias, k de 1 a 40.

5. Clúster jerárquico

El clúster jerárquico arranca con cada observación como su propio grupo y las va uniendo de a pares, según se parezcan, hasta dejar todo en un solo grupo. Ese proceso se dibuja en un dendrograma, un árbol donde la altura a la que se juntan dos ramas indica qué tan distintos eran los grupos que se fusionan, cuanto más abajo se unen, más parecidos son. El número de clústeres sale de cortar el árbol a cierta altura. Como en clase se recomendó probar varios métodos de fusión, comparamos Ward, complete, average y single con la correlación cofenética, que mide qué tan bien el dendrograma respeta las distancias reales (Ward 0,42; complete 0,51; average 0,80; single 0,76). Average es el que más la maximiza porque promedia las mismas distancias que la métrica evalúa. Nos quedamos con Ward que minimiza la varianza dentro de cada grupo, que es el mismo criterio de k-medias, y además hace que los dos métodos sean comparables.



Fuente: elaboración propia en base a EPH-INDEC, 4° trimestre 2024 y 2025.

Figura 5. Dendrograma con enlace de Ward (submuestra de 300 observaciones).

Al cortar el árbol en dos grupos sobre una muestra de 2.000 casos, el resultado repite el de k-medias: 82,5% y 82,8% de informales en cada rama, con perfiles que se diferencian básicamente en la edad (35,5 contra 55,7 años). Con muestras de 300 casos el resultado era inestable y variaba según la muestra sorteada, así que preferimos verificarlo con la más grande. Es de esperar que los tres métodos numéricos coincidan, ya que todos buscan estructura en las mismas siete variables continuas, y ahí lo que ordena a la población es la edad, no la informalidad.

6. K-modas

K-modas es la versión de k-medias para variables categóricas, pero usa modas en lugar de medias, este método mide distancias por coincidencias. Como insumo tomamos las nueve *dummies* del TP1 (sexo, pareja, cobertura médica, categoría ocupacional, sector, subocupación) y las cuatro variables nuevas pasadas a tramos (edad, educación, horas y tamaño del hogar), dejando afuera la variable informal como pide la consigna. Con k=2 e iniciación de Huang -que dio un costo menor que Cao, 42.241 contra 44.302, las dos vistas en clase- pasa algo distinto a los métodos anteriores. Uno de los grupos es casi todo informal (95,5%) y el otro es mixto (66,6%). La coincidencia con la clasificación real (64,7%) no llega a superar la línea de base de clasificar todo como informal (81,2%), pero la diferencia de composición entre los dos grupos es de 29

puntos. Eso indica que las variables categóricas sí traen información sobre la informalidad que las numéricas no tenían ya que la falta de cobertura médica o el sector de la unidad económica son casi sinónimos de informalidad.




Figura 6. Método del codo para k-modas.

El codo termina de confirmarlo (Figura 6). Mientras que en k-medias la curva bajaba sin quiebres, acá el costo cae un 17,7% al pasar de uno a dos grupos y después mucho menos cómo ve el codo en $k=2$. La diferencia entre los dos métodos no pasa tanto por lo técnico, donde uno compara categorías y el otro mide distancias, sino por lo que miden, las variables categóricas separan en dos grupos, las continuas no. Ese contraste es el resultado central de la Parte II.

Parte III. Uso de herramientas de IA y reflexión final

Se utilizó inteligencia artificial como herramienta de apoyo para la construcción de variables, revisar la implementación de los métodos de reducción de dimensionalidad y agrupamiento, y ayudar en la interpretación de resultados que inicialmente generaban dudas, como la ausencia de un codo claro en k-medias o la escasa separación entre trabajadores formales e informales.

Tiempo total dedicado al trabajo práctico: Mayra Lemes 18 horas ; Javier Hernández 18 horas

El registro completo de los prompts utilizados, transcritos textualmente y en orden, con su resultado verificado, se presenta en el Apéndice A.

Referencias

- Cao, F., Liang, J. y Bai, L. (2009). A new initialization method for categorical data clustering. *Expert Systems with Applications*, 36(7), 10223-10228.
- Huang, Z. (1998). Extensions to the k-means algorithm for clustering large data sets with categorical values. *Data Mining and Knowledge Discovery*, 2(3), 283-304.
- INDEC. Encuesta Permanente de Hogares: diseño de registro y estructura para las bases preliminares, cuartos trimestres de 2024 y 2025.
- James, G., Witten, D., Hastie, T. y Tibshirani, R. (2023). *An Introduction to Statistical Learning with Applications in Python*. Springer.
- Maurizio, R. y Monsalvo, A. P. (2021). Informality, labour transitions, and the livelihoods of workers in Latin America. *WIDER Working Paper 2021/19*, UNU-WIDER.
- Schwabish, J. A. (2014). An economist's guide to visualizing data. *Journal of Economic Perspectives*, 28(1), 209-234.
- Sosa Escudero, W. (2019). *Big data: breve manual para conocer la ciencia de datos que ya invadió nuestras vidas*. Siglo XXI Editores.

Apéndice A. Registro de prompts a la inteligencia artificial

Se presentan los principales prompts utilizados durante el desarrollo del trabajo, junto con una breve descripción de cómo se verificó cada resultado. Las consultas relacionadas únicamente con aspectos operativos (rutas de archivos, configuración del entorno o errores de ejecución) se omiten por no aportar al contenido metodológico. Se usó Chatgpt como herramienta de IA

Prompt 1. Construcción de la variable educ

Estamos construyendo la variable de años de educación usando CH12, CH13 y CH14 de la EPH. ¿Cuál sería una forma consistente de asignar los años aprobados para cada nivel educativo, incluyendo los casos incompletos?

Resultado y verificación: Se obtuvo una propuesta de mapeo que luego se contrastó con la consigna y con tabulaciones de la base. La asignación final fue validada verificando que los casos de secundario completo recibieran 12 años y que el resto de los niveles fueran consistentes.

Prompt 2. Interpretación del PCA

El primer componente está dominado por edad y edad² y necesitamos cinco componentes para explicar más del 90 % de la varianza. ¿Cómo debería interpretarse este resultado?

Resultado y verificación: La explicación sugería que la baja correlación entre la mayoría de las variables limita la capacidad de reducción de dimensionalidad. Esa interpretación se contrastó con las simulaciones vistas en clase antes de incorporarla al informe.

Prompt 3. K-medias

Aplicamos k-medias con k=2 y los clústeres prácticamente no distinguen trabajadores formales e informales. ¿Puede ser un resultado válido? ¿Cómo debería explicarse?

Resultado y verificación: Se concluyó que el algoritmo estaba agrupando principalmente por edad y no por informalidad. La interpretación se verificó comparando los centroides y los resultados del PCA.

Prompt 4. Clúster jerárquico

¿Tiene sentido comparar varios métodos de enlace (Ward, complete, average y single) antes de elegir el dendrograma que se presentará en el informe?

Resultado y verificación: Se recomendó comparar las correlaciones cofenéticas de los distintos métodos. Finalmente se seleccionó Ward por ser el criterio más comparable con k-medias.

Prompt 5. K-modas

Para las variables categóricas, ¿conviene utilizar la inicialización de Huang o la de Cao? ¿Cómo justificar la elección en el informe?

Resultado y verificación: Se probaron ambas alternativas y se eligió la que produjo el menor costo de agrupamiento. La decisión quedó respaldada por los resultados obtenidos.

Apéndice B. Validación de la variable educ

Tabulación cruzada de educ contra el nivel más alto cursado (CH12), para las categorías con mayor frecuencia. Confirma que la construcción asigna los años correctos a cada nivel: los 1.573 casos con secundario completo reciben 12 años, los universitarios completos 17-18, etc.

Tabla B.1. Correspondencia entre nivel educativo (CH12) y años asignados (educ).

CH12 (nivel)	educ típico	Casos
Primaria (2)	7 años	1.573
Secundaria (4)	12 años	1.305 (con 6° aprobado)
Terciario (6)	15 años	998
Universitario (7)	17-18 años	1.305
Posgrado (8)	19-22 años	133 (22 años)
Sin dato / especial	NaN	133

Apéndice C. Estadística descriptiva completa por año

Todas las variables numéricas, por trimestre. Ingresos reales en pesos de 2025T4. Base: universo self-employed.

Tabla C.1. Descriptiva por año (2024 y 2025). N, promedio, desvío y cuartiles.

Variable	N 24	Prom 24	SD 24	P25 24	P50 24	P75 24	N 25	Prom 25	SD 25	P25 25	P50 25	P75 25
Edad	5.840	44,6	14,2	33	44	55	5.755	45,1	14,2	34	45	56
Edad²	5.840	2.193	1.325	1.089	1.936	3.025	5.755	2.238	1.333	1.156	2.025	3.136
Educación	5.780	12,0	3,8	10	12	15	5.682	11,8	3,8	9	12	15
Horas totales	5.824	36,6	19,1	22	40	48	5.741	36,9	19,3	23	40	48
Miembros hogar	5.840	3,4	1,7	2	3	4	5.755	3,5	1,7	2	3	4
P21 real	4.340	679.921	905.259	197.116	420.514	788.464	4.309	831.926	1.221.576	280.000	500.000	1.000.000
P47T real	4.241	827.182	1.019.967	315.385	565.066	959.298	4.198	988.015	1.373.141	400.000	650.000	1.100.000
Tamaño estab.	5.781	1,7	1,3	1	1	2	5.705	1,6	1,3	1	1	2

Apéndice D. Casos atípicos identificados en el PCA

Las diez observaciones más alejadas del origen en el plano PC1-PC2. Corresponden a ingresos extremos (hasta \$30 millones), en su mayoría cuentapropistas con educación alta.

Tabla D.1. Observaciones atípicas en el espacio de componentes principales.

Edad	Educación	Miembros	Ingreso P21	Tamaño	Informal
40	12	4	11.000.000	6	Formal
73	22	2	6.000.000	10	Formal
71	18	2	12.000.000	2	Informal
55	22	2	15.000.000	2	Informal
62	18	5	15.000.000	2	Formal
34	18	2	20.000.000	1	Formal
58	15	2	30.000.000	1	Formal

Apéndice E. Perfiles de clúster y tablas de codo

Centroides de los clústeres de k-medias y jerárquico, y evolución de la medida de disimilitud en ambos métodos de codo.

Tabla E.1. Perfiles promedio (centroides) de los clústeres numéricos.

Método / Clúster	Edad	Educación	Horas	Miembros	Ingreso	Tamaño
K-medias 0	35,2	12,3	36,5	3,9	619.890	1,6
K-medias 1	58,7	11,1	36,0	2,8	755.519	1,7
Jerárquico 1	41,1	15,0	38,8	2,8	1.467.024	4,1
Jerárquico 2	44,3	11,1	35,4	3,5	477.620	1,2

Tabla E.2. Evolución de la disimilitud en el método del codo (primeros valores de k).

k	Inercia k-medias	Caída %	Costo k-modas	Caída %
2	47.287	-20,7%	42.241	-17,7%
3	40.692	-13,9%	38.649	-8,5%
4	36.481	-10,3%	36.694	-5,1%
5	33.540	-8,1%	34.487	-6,0%
6	30.981	-7,6%	34.341	-0,4%